

Conceitos e Aplicações de Aprendizado de Máquina

Aula 2: Aprendizagem Não Supervisionada e “Explicabilidade” de Modelos

Eduardo Krempser
Assessoria de Inteligência Competitiva - AICOM
Instituto de Tecnologia em Imunobiológicos - Bio-Manguinhos
Fundação Oswaldo Cruz - Fiocruz

Pedro Henrique Monteiro Torres
Instituto de Biofísica Carlos Chagas Filho - IBCCF
Universidade Federal do Rio de Janeiro - UFRJ



Aprendizagem Não Supervisionada

Localização	Quartos	Garagem	...	Grupo
Copacabana	2	Não	...	?
Copacabana	1	Sim	...	?
Centro	2	Não	...	?
Barra da Tijuca	3	Sim	...	?
...	...	...	...	...

Aprendizagem Não Supervisionada

Localização	Quartos	Garagem	...	Grupo
Copacabana	2	Não	...	?
Copacabana	1	Sim	...	?
Centro	2	Não	...	?
Barra da Tijuca	3	Sim	...	?
...	...	...	...	...

Aprendizagem Não Supervisionada

Localização	Quartos	Garagem	...	Grupo
Copacabana	2	Não	...	?
Copacabana	1	Sim	...	?
Centro	2	Não	...	?
Barra da Tijuca	3	Sim	...	?
...	...	...	...	...

Aprendizagem Não Supervisionada

$h($

Localização	Quartos	Garagem	...	Grupo
Copacabana	2	Não	...	?
Copacabana	+	Sim	) ...	?
Centro	2	Não	...	?
Barra da Tijuca	3	Sim	...	?
...	...	...	...	...

Aprendizagem Não Supervisionada

$h($


Localização	Quartos	Garagem	...	Grupo
Copacabana	2	Não	...	?
Copacabana	+	Sim	) ...	?
Centro	2	Não	...	?
Barra da Tijuca	3	Sim	...	?
...	...	...	...	...

Aprendizagem Não Supervisionada

Base de dados das Flores de Íris

Iris flower dataset

Setosa




Ирис шестилепестный (Кавказка), Domínio público, via Wikimedia Commons

Versicolor




Charles de Mille-Isles from Mille-Isles, Canada, CC BY 2.0, via Wikimedia Commons

Virginica




Robert H. Mohlenbrock. Courtesy of USDA NRCS, Public domain, via Wikimedia Commons


Aprendizagem Não Supervisionada




Aprendizagem Não Supervisionada




Aprendizagem Não Supervisionada




Aprendizagem Não Supervisionada




Aprendizagem Não Supervisionada




Aprendizagem Não Supervisionada



Aprendizagem Não Supervisionada



Aprendizagem Não Supervisionada




Qual resultado é “melhor”?
Como escolher o número de agrupamentos (*clusters*)?


Aprendizagem Não Supervisionada

- Medidas para avaliação de modelos:
 - Silhouette Score
 - Compara a distância média dentro do próprio *cluster* com a distância média ao *cluster* vizinho mais próximo
 - Davies-Bouldin Index
 - Mede o quanto os *clusters* são compactos e o quanto estão separados uns dos outros
 - Calinski-Harabasz Index
 - Razão entre dispersão entre *clusters* e dispersão dentro dos *clusters*
 - Dunn Index
 - Razão entre a menor distância entre clusters diferentes e o maior diâmetro interno de um cluster
 - Inertia
 - Soma das distâncias ao quadrado de cada ponto até o centróide do seu cluster
 - ...

Aprendizagem Não Supervisionada



Aprendizagem Não Supervisionada



Aprendizagem Não Supervisionada

EFEITO DA ESCALA DE ATRIBUTOS NO AGRUPAMENTO K-MEANS

ANTES: ATRIBUTOS COM ESCALAS DIFERENTES



DADOS NÃO NORMALIZADOS


Se os atributos tiverem escalas muito diferentes, o k-means focará apenas na variável de maior escala, ignorando as outras.




CÁLCULO DE DISTÂNCIA

Distância Euclidiana

$$d(P1, P2) = \sqrt{(X_1 - X_2)^2 + (Y_1 - Y_2)^2}$$



RESULTADO DO K-MEANS (K=3)



DEPOIS: ATRIBUTOS COM MESMA ESCALA



DADOS NORMALIZADOS


A normalização (por exemplo, Min-Max ou Z-score) coloca todas as variáveis na mesma escala, permitindo que cada uma contribua igualmente.



CÁLCULO DE DISTÂNCIA

Distância Euclidiana


$$d(P1, P2) = \sqrt{(X_{\text{norm}} - X_{\text{norm}})^2 + (Y_{\text{norm}} - Y_{\text{norm}})^2}$$



RESULTADO DO K-MEANS (K=3)



CONCLUSÃO: A normalização de dados é um passo essencial antes do k-means para evitar clusters imprecisos e tendenciosos.



Como “entender” os resultados?





Interpretação/Explicação dos Modelos

- Inteligência Artificial explicável (XAI - Explainable artificial intelligence)
 - Tornar seus processos de tomada de decisão compreensíveis e transparentes para os usuários
 - A explicabilidade é um requisito emergente para sistemas baseados em IA que utilizam técnicas de aprendizagem de máquina (ML).
 - Necessidades como:
 - aumento da transparência
 - refinamento de modelos
 - mitigação de vieses
 - Exemplos de métodos:
 - Mean Decrease in Impurity (MDI) / Global Feature Importance (GFI)
 - SHapley Additive exPlanations (SHAP)
 - Local Interpretable Model-Agnostic Explanation (LIME)

Interpretação/Explicação dos Modelos

```
import pandas as pd
from sklearn.tree import DecisionTreeClassifier # Import Decision Tree Classifier
from sklearn.model_selection import train_test_split # Import train_test_split function
from sklearn import metrics
from matplotlib import pyplot as plt
from sklearn import tree

datafile = "iris.csv"
df = pd.read_csv(datafile, header = 0)
display(df)

feature_cols = ['sepal_length', 'sepal_width', 'petal_length', 'petal_width']
X = df[feature_cols]
y = df.species

# 70% treinamento e 30% para teste
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=1)


clf = DecisionTreeClassifier()

# Train Decision Tree Classifier
clf = clf.fit(X_train,y_train)


#Predict the response for test dataset
y_pred = clf.predict(X_test)

print("Accuracy:",metrics.accuracy_score(y_test, y_pred))



fig, axes = plt.subplots(nrows = 1,ncols = 1,figsize = (5,5), dpi=300)
tree.plot_tree(clf, filled=True)
plt.show()
```




Interpretação/Explicação dos Modelos




Interpretação/Explicação dos Modelos




Interpretação/Explicação dos Modelos




Interpretação/Explicação dos Modelos



Comentários adicionais




Comentários adicionais




“Maldição” da Dimensionalidade

Comentários adicionais



Comentários adicionais



Viés do Sobrevivente



Comentários adicionais

- Por que os métodos de Aprendizagem de Máquina merecem tanta atenção?
 - Permite trilhar caminhos na descoberta de conhecimento
 - Produz soluções factíveis para problemas até então sem soluções
 - Mecanismos altamente paralelizáveis (CPU e GPU)
 - Permitem a integração com especialistas na formulação/avaliação
 - Aplicação intrinsecamente interdisciplinar
 - . . .





Comentários adicionais

- Por que os métodos de Aprendizagem de Máquina merecem tanta atenção?
 - Permite trilhar caminhos na descoberta de conhecimento
 - Produz soluções factíveis para problemas até então sem soluções
 - Mecanismos altamente paralelizáveis (CPU e GPU)
 - Permitem a integração com especialistas na formulação/avaliação
 - Aplicação intrinsecamente interdisciplinar
 - . . .

Mas... não são a solução de todos os seus problemas!



Obrigado

Eduardo Krempser
Assessoria de Inteligência Competitiva
Bio-Manguinhos/Fiocruz

Pedro Henrique Monteiro Torres
Instituto de Biofísica Carlos Chagas Filho - IBCCF
Universidade Federal do Rio de Janeiro - UFRJ

